

**HYBRIDIZATION OF SVM-BASED UNDERSAMPLING DAN
SAFE-LEVEL SMOTE UNTUK PENINGKATAN KLASIFIKASI
PADA DATASET GELOMBANG OSEANOGRAFI YANG TIDAK
SEIMBANG**

IF25-35025 / DATA MINING



Kelompok 05

Topik : Imbalanced Data - Hybrid Oversampling & Undersampling (HOUM)

Disusun Oleh :

Mekar Cendra Narwastu	(123140074)
Mei Disti Ayuningtias	(123140076)
Ribka Hana Josephine Situmorang	(123140103)
Abel Fortino	(123140111)
Diwan Ramadhani Dwi Putra	(123140116)
M. Zahran Dhiyaul Haq	(123140120)

**PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS TEKNOLOGI INDUSTRI
INSTITUT TEKNOLOGI SUMATERA
LAMPUNG SELATAN
2026**

ABSTRAK

Ketidakseimbangan kelas (*imbalanced dataset*) merupakan tantangan utama dalam penambangan data, di mana model klasifikasi cenderung bias terhadap kelas mayoritas sehingga kemampuan mendeteksi kelas minoritas menjadi rendah. Penelitian ini mengimplementasikan metode *Hybrid Oversampling and Undersampling Method* (HOUM) yang menggabungkan SVM-based undersampling dan Safe-Level SMOTE untuk mengatasi permasalahan tersebut. Dataset yang digunakan adalah data observasi gelombang di perairan Indonesia yang diklasifikasikan ulang berdasarkan standar skala meteorologi maritim internasional. Ekstraksi kelas didistribusikan menjadi kondisi Normal (<1.25 m) sekitar 91%, Moderate (1.25-2.5 m) sekitar 8%, Rough (2.5-4 m) sekitar 0.8%, dan Very Rough (>4 m) sekitar 0.1%. Transformasi target pemodelan ini secara faktual memunculkan representasi anomali cuaca yang sesungguhnya dan menghasilkan rasio ketidakseimbangan kelas ekstrem hingga melampaui 1:100. Eksperimen membandingkan empat skenario: Baseline, Random Undersampling (RUS), NearMiss-1, dan HOUM menggunakan classifier Random Forest dengan stratified train-test split 80:20. Metrik evaluasi meliputi Accuracy, Precision, Recall, F1-Score, G-Mean, dan AUC yang representatif untuk kondisi imbalanced. Hasil eksperimen menunjukkan bahwa HOUM menghasilkan keseimbangan terbaik antara Precision dan Recall pada kelas-kelas minoritas, dengan nilai G-Mean dan F1-Score yang lebih kompetitif dibandingkan RUS dan NearMiss-1. Nilai AUC HOUM pada kelas Slight dan Moderate konsisten lebih tinggi dari Baseline, mengkonfirmasi keunggulan metode hybrid ini dalam menangani ketidakseimbangan data yang ekstrim.

Kata Kunci: *HOUM, Imbalanced Dataset, Klasifikasi, Oseanografi, Random Forest, Safe-Level SMOTE, SVM-based Undersampling.*

DAFTAR ISI

ABSTRAK.....	2
DAFTAR ISI.....	3
DAFTAR TABEL.....	5
DAFTAR GAMBAR.....	6
BAB I	
PENDAHULUAN.....	7
1.1 Latar Belakang.....	7
1.2 Rumusan Masalah.....	8
1.3 Tujuan Penelitian.....	8
1.4 Batasan Masalah.....	8
BAB II	
TINJAUAN PUSTAKA.....	9
2.1 Data Mining dan Preprocessing.....	9
2.2 Imbalanced Dataset.....	9
2.3 Metode Penanganan Imbalanced Data.....	9
2.3.1 Random Undersampling (RUS).....	9
2.3.2 NearMiss-1.....	10
2.3.3 Safe-Level SMOTE (SL-SMOTE).....	10
2.3.4 SVM-Based Undersampling.....	10
2.4 Hybrid Oversampling and Undersampling Method (HOUM).....	10
2.5 Metrik Evaluasi untuk Imbalanced Data.....	11
2.6 Penelitian Terkait.....	11
BAB III	
METODOLOGI PENELITIAN.....	13
3.1 Alur Penelitian.....	13
3.2 Deskripsi Dataset.....	14
3.2.1 Dataset Gelombang Laut di Perairan Indonesia.....	14
3.2.2 Dataset Rain in Australia.....	15
3.3 Prosedur Eksperimen.....	15
3.3.1 Pembagian Data (Train-Test Split).....	15
3.3.2 Metode Resampling yang Digunakan.....	16
3.3.3 Algoritma Klasifikasi.....	17
3.3.4 Metrik Evaluasi.....	17
BAB IV	
HASIL DAN PEMBAHASAN.....	19
4.1 Eksplorasi Data (EDA).....	19
4.1.1 Interpretasi EDA.....	19

4.1.2 Interpretasi Preprocessing dan Resampling.....	21
4.2 Pembahasan.....	22
BAB V	
KESIMPULAN.....	23
5.1 Kesimpulan.....	23
5.2 Keterbatasan.....	23
5.3 Saran.....	23
DAFTAR PUSTAKA.....	24
LAMPIRAN.....	25

DAFTAR TABEL

Tabel 2.1 Metrik Evaluasi.....	11
Tabel 3.1 Deskripsi Dataset Gelombang Laut di Perairan Indonesia.....	14
Tabel 3.2 Deskripsi Fitur Dataset Gelombang Laut di Perairan Indonesia.....	14
Tabel 3.3 Deskripsi Dataset Rain in Australia.....	15
Tabel 3.4 Deskripsi Fitur Dataset Rain in Australia.....	15
Tabel 3.5 Metrik Evaluasi yang Digunakan.....	17

DAFTAR GAMBAR

Gambar 3.1 Alur Penelitian.....	13
Gambar 4.1 Distribusi kelas gelombang dan sebaran Hsig(m) per kategori.....	19
Gambar 4.2 Distribusi Fitur Oseanografi per Kelas Gelombang.....	19
Gambar 4.3 Heatmap korelasi antar fitur dataset gelombang.....	20
Gambar 4.4 Distribusi kelas pada keempat skenario resampling (data latih).....	20
Gambar 4.5 Perbandingan Metrik Evaluasi per Skenario Resampling.....	21
Gambar 4.6 Confusion Metrik Keempat Skenario Resampling.....	21

BAB I

PENDAHULUAN

1.1 Latar Belakang

Penambangan data (data mining) adalah proses menemukan pola dan pengetahuan yang berguna dari kumpulan data yang besar. Salah satu tantangan yang sering muncul dalam klasifikasi data adalah imbalanced dataset, yaitu kondisi dimana jumlah sampel antar kelas sangat tidak seimbang. Ketika ini terjadi, model cenderung lebih banyak belajar dari kelas yang jumlahnya besar (mayoritas) dan mengabaikan kelas yang jumlahnya kecil (minoritas), padahal kelas minoritas seringkali justru lebih penting [1].

Dalam bidang oseanografi, data gelombang laut yang dikumpulkan dari stasiun pengukuran umumnya didominasi oleh kondisi normal (*Smooth*), sementara kondisi gelombang yang lebih tinggi seperti *Slight* atau *Moderate* jauh lebih jarang terjadi. Padahal, kemampuan mendeteksi kondisi gelombang yang berpotensi berbahaya ini sangat penting untuk keselamatan pelayaran dan operasional maritim.

Berbagai teknik telah dikembangkan untuk mengatasi ketidakseimbangan data. SMOTE [2] adalah salah satu yang paling populer, yaitu dengan membuat sampel sintetis baru dari kelas minoritas. Namun, SMOTE kadang menghasilkan sampel di area yang tumpang-tindih dengan kelas lain. Di sisi lain, metode undersampling seperti Random Undersampling bisa membuang data mayoritas yang sebenarnya penting [3]. Mayoritas model pembelajaran mesin di bidang oseanografi saat ini terlalu berfokus pada prediksi regresi deret waktu kontinu dan mengalami degradasi performa yang signifikan ketika dihadapkan pada klasifikasi peringatan dini skala diskrit ekstrem. Selain itu, perairan kepulauan Indonesia secara historis memiliki kesenjangan observasi spasial-temporal yang masif. Untuk mengisi kesenjangan tersebut, penelitian ini mengimplementasikan metode mutakhir Hybrid Oversampling and Undersampling Method (HOUM). Pembeda utama (*novelty*) riset ini dari studi sebelumnya terletak pada ekstrapolasi algoritma HOUM dari lingkungan kontrol industri menuju sistem termodinamika lautan terbuka, serta modifikasi arsitektur algoritmik dari klasifikasi biner bawaan menjadi skema partisi ansambel multikelas berskala ekstrem.[4]. Metode ini diuji pada dataset gelombang dari enam lokasi di Indonesia dengan total 61.230 data dan ketidakseimbangan hingga rasio 13:1.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, permasalahan yang diidentifikasi dalam penelitian ini adalah sebagai berikut:

1. Seberapa besar ketidakseimbangan kelas pada dataset gelombang oseanografi, dan bagaimana dampaknya terhadap model klasifikasi baseline?
2. Bagaimana perbandingan performa HOUM dengan RUS dan *NearMiss-1* dalam mendeteksi kelas gelombang minoritas?
3. Apakah HOUM secara konsisten menghasilkan nilai *F1-Score*, *G-Mean*, dan AUC yang lebih baik dibandingkan metode undersampling konvensional?

1.3 Tujuan Penelitian

Berdasarkan rumusan masalah yang telah diidentifikasi, penelitian ini memiliki tujuan sebagai berikut:

1. Mengidentifikasi tingkat ketidakseimbangan kelas pada dataset gelombang oseanografi dan dampaknya terhadap model baseline.
2. Membandingkan performa HOUM terhadap RUS dan *NearMiss-1* dalam skenario klasifikasi *imbalanced*.
3. Mengevaluasi keunggulan metode hybrid HOUM menggunakan metrik yang komprehensif dan representatif.

1.4 Batasan Masalah

Batasan yang dimaksud disini ialah:

1. Dataset terbatas pada enam lokasi pengukuran gelombang di perairan Indonesia periode Juli–Agustus 2024.
2. Classifier yang digunakan adalah Random Forest dengan parameter standar ($n_estimators=100$).
3. Evaluasi dilakukan pada data uji yang tidak mengalami perubahan (asli) untuk mensimulasikan kondisi nyata.
4. Penelitian ini tidak melakukan optimasi hyperparameter model.

BAB II

TINJAUAN PUSTAKA

2.1 Data Mining dan Preprocessing

Secara umum, data mining merupakan proses untuk menemukan pola-pola penting dari kumpulan data berukuran besar menggunakan metode statistik dan komputasi [1]. Namun, sebelum data tersebut bisa diolah oleh algoritma machine learning, data mentah harus melewati tahap *preprocessing* terlebih dahulu. Tahapan ini sangat krusial dan mencakup pembersihan data, penanganan data yang kosong (*missing values*), penyesuaian fitur, serta penanganan rasio kelas yang tidak seimbang. Pada akhirnya, performa dan akurasi model klasifikasi yang dihasilkan akan sangat bergantung pada seberapa baik proses preprocessing tersebut dilakukan.

2.2 Imbalanced Dataset

Sebuah dataset dikatakan mengalami imbalanced data apabila jumlah sampel pada satu kelas jauh mendominasi kelas lainnya. Tingkat ketimpangan ini biasanya diukur menggunakan *Imbalance Ratio* (IR), yaitu hasil perbandingan antara jumlah data di kelas mayoritas dengan kelas minoritas. Jika nilai IR sudah melebihi 10:1, dataset tersebut masuk dalam kategori ketidakseimbangan ekstrem yang wajib diberikan penanganan khusus [1]. Jika dibiarkan, kondisi ini akan memicu terjadinya accuracy paradox, yaitu situasi di mana model seolah-olah memiliki metrik akurasi yang tinggi secara keseluruhan, padahal performanya sangat buruk dalam memprediksi kelas minoritas yang justru menjadi fokus utama dalam implementasi nyata.

2.3 Metode Penanganan Imbalanced Data

2.3.1 Random Undersampling (RUS)

Teknik ini bekerja dengan cara mengurangi jumlah data pada kelas mayoritas secara acak sampai proporsinya seimbang dengan kelas minoritas. Walaupun metodenya sangat cepat dan praktis, RUS memiliki kelemahan besar yaitu tingginya risiko membuang sampel data mayoritas yang sebenarnya masih memiliki informasi penting untuk pemodelan [3].

2.3.2 NearMiss-1

Merupakan teknik undersampling yang memanfaatkan perhitungan jarak (*distance-based*). Algoritma ini hanya akan mempertahankan sampel dari kelas mayoritas yang jarak rata-ratanya paling dekat dengan tiga sampel kelas minoritas terdekat. Meskipun jauh lebih selektif dibandingkan RUS, *NearMiss-1* masih berisiko membuang data mayoritas yang letaknya jauh dari batas kelas, padahal bisa jadi data tersebut tetap informatif [5].

2.3.3 Safe-Level SMOTE (SL-SMOTE)

Ini adalah versi modifikasi dari algoritma SMOTE konvensional. Pendekatan ini lebih berhati-hati karena hanya akan membangkitkan data sintetis baru pada area yang dianggap aman (*safe area*). Tingkat keamanan ini diukur menggunakan *safe-level*, yakni berdasarkan jumlah tetangga terdekat yang murni berasal dari kelas minoritas. Semakin tinggi nilai *safe-level*-nya, semakin aman area tersebut untuk di generate data baru, sehingga meminimalisir terjadinya tumpang-tindih (*overlapping*) antar kelas [9].

2.3.4 SVM-Based Undersampling

Teknik ini memanfaatkan konsep *support vectors* dari algoritma *Support Vector Machine* (SVM) untuk menyeleksi sampel mana yang paling krusial di sekitar batas keputusan (*decision boundary*). Data dari kelas mayoritas yang posisinya jauh dari batas tersebut akan dihapus, sementara data yang berada tepat di dekat batas akan tetap dipertahankan karena dianggap membawa informasi klasifikasi yang sangat penting [6].

2.4 Hybrid Oversampling and Undersampling Method (HOUM)

Metode ini merupakan gabungan adaptif antara SVM-based undersampling dan *Safe-Level* SMOTE yang dijalankan secara iteratif atau berulang [4]. Alur kerjanya dimulai dengan melatih model SVM pada data yang masih timpang, lalu menghapus sampel mayoritas yang posisinya jauh dari batas keputusan. Setelah itu, SL-SMOTE diterapkan untuk meng-generate sampel minoritas tambahan hanya pada area yang sudah dipastikan aman. Siklus ini terus diulang sampai rasio target kelas yang diinginkan tercapai. Keunggulan utama HOUM adalah kemampuannya menyelesaikan dua masalah klasik sekaligus: mencegah hilangnya data penting akibat undersampling acak, serta menghindari overfitting yang sering terjadi akibat proses oversampling yang tidak terkontrol.

2.5 Metrik Evaluasi untuk Imbalanced Data

Mengingat tingginya ketidakseimbangan kelas pada studi kasus ini, penggunaan metrik akurasi saja bisa sangat menyesatkan. Oleh karena itu, penelitian ini menggunakan serangkaian metrik evaluasi yang lebih representatif.

Tabel 2.1 Metrik Evaluasi

Metrik	Keterangan
Accuracy	Persentase total prediksi model yang tepat secara keseluruhan.
Precision	Mengukur seberapa presisi atau tepat tebakan model terhadap kelas positif (seberapa banyak prediksi benar dari total yang ditebak positif).
Recall (Sensitivity)	Mengukur kemampuan dan kepekaan model dalam mendeteksi dan mengenali seluruh sampel asli dari kelas minoritas.
F1-Score	Nilai rata-rata harmonis (harmonic mean) yang berfungsi menyeimbangkan bobot antara Precision dan Recall.
G-Mean (Geometric Mean)	Akar kuadrat dari hasil perkalian antara Sensitivity dan Specificity; metrik ini sangat sensitif dan akan memberikan penalti besar jika model mengklasifikasikan salah satu kelas dengan sangat buruk.
AUC (Area Under the ROC Curve)	Luasan area di bawah kurva ROC yang menunjukkan seberapa baik model mampu membedakan (melakukan diskriminasi) antar kelas.

2.6 Penelitian Terkait

Beberapa penelitian sebelumnya telah membuktikan efektivitas pendekatan hybrid dalam menangani ketidakseimbangan data. Pendekatan algoritmik Hybrid Oversampling and Undersampling Method (HOUM) secara formal baru diperkenalkan pada tahun 2024 oleh Duygu Yilmaz Eroglu dan Mestan Sahin Pir melalui jurnal bereputasi tinggi, Applied Sciences. Pada literatur orisinalnya, metode hibrida komputasi ini dibangun sebagai sistem pendukung keputusan fokal untuk memprediksi dan mencegah anomali kerusakan benang (yarn breakage) secara real-time di dalam industri manufaktur tekstil. Kemampuan superior HOUM dalam meminimalisir kehilangan informasi pada kelas mayoritas menjadikannya

landasan yang sangat kuat untuk diadaptasi ke ranah prediksi kebencanaan maritim. Hasilnya menunjukkan bahwa HOUM berhasil mengungguli metode kompetitor (seperti SMOTE, SMOTEENN, dan SMOTETomek) pada 5 dari 8 dataset, khususnya dari segi metrik G-Mean dan Recall.


Selanjutnya, studi oleh Mujahid dkk. [7] yang mengevaluasi berbagai teknik oversampling pada data teks yang imbalanced menyimpulkan bahwa kombinasi metode hybrid mampu memberikan performa model terbaik. Hal ini sejalan dengan temuan Trisanto dkk. [8] pada studi kasus deteksi kecurangan (fraud) kartu kredit, yang sangat menekankan bahwa dalam kondisi data yang tidak seimbang, metrik seperti *Recall* dan *G-Mean* jauh lebih dapat diandalkan untuk dijadikan patokan performa dibandingkan sekadar berpatokan pada tingkat akurasi.

BAB III

METODOLOGI PENELITIAN

3.1 Alur Penelitian

Pada penelitian ini, alur dirancang untuk memastikan setiap tahapan pemrosesan dilakukan secara sistematis dan efisien. Alur ini menggambarkan langkah-langkah dari awal hingga akhir yang dibuat dalam bentuk diagram alir (*flowchart*), seperti yang terlihat pada Gambar 3.1.



Gambar 3.1 Alur Penelitian

Pipeline penelitian ini dirancang untuk menghindari data *leakage* (kebocoran data), yaitu kondisi di mana informasi dari data uji masuk ke proses pelatihan. Urutan langkahnya adalah sebagai berikut :

1. Load Dataset (6 file XLSX gelombang)
2. Gabung & Preprocessing Dasar (hapus NaN, encode target)
3. Exploratory Data Analysis (EDA)
4. Train-Test Split Stratified 80:20

5. StandardScaler, lakukan hanya pada data latih (X_train)
6. Resampling (hanya pada data latih) menggunakan metode Baseline, RUS, NearMiss-1, HOUM
7. Training Random Forest (satu model per skenario)
8. Evaluasi pada data uji asli (tidak diubah)
9. Visualisasi & Pembahasan

3.2 Deskripsi Dataset

Dataset yang digunakan berasal dari enam stasiun pengukuran gelombang laut di perairan Indonesia.

3.2.1 Dataset Gelombang Laut di Perairan Indonesia

Tabel 3.1 Deskripsi Dataset Gelombang Laut di Perairan Indonesia

Atribut	Deskripsi
Sumber Data	6 File XLSX (Gelombang 1-6)
Total Sample	61.230 Baris
Jumlah Fitur	9 Fitur Numerik
Variabel Target	Hsig(Scale) : Smooth, Slight, Moderate
Distribusi Kelas	Smooth: 84,98%; Moderate: 8,65%; Slight: 6,38%
Imbalance Ratio	~13:1 (Smooth vs Slight)

Tabel 3.2 Deskripsi Fitur Dataset Gelombang Laut di Perairan Indonesia

Fitur	Deskripsi
WaveDir(deg)	Arah gelombang (derajat)
PrimSwell(m)	Tinggi gelombang primer/swell (meter)
WindSea(m)	Tinggi gelombang akibat angin (meter)
WavePeriod(s)	Periode gelombang (detik)
SurfCurrentSpd(cm/s)	Kecepatan arus permukaan (cm/s)
SeaSurfaceTemperature(°C)	Suhu permukaan laut (°C)
SeaSurfaceSalinity(PSU)	Salinitas permukaan laut
WindSpeed(knots)	Kecepatan angin (knots)
WindDir(deg)	Arah angin (derajat)

3.2.2 Dataset Rain in Australia

Tabel 3.3 Deskripsi Dataset Rain in Australia

Atribut	Deskripsi
Sumber Data	Kaggle (jsphyg/weather-dataset-rattle-package)
Total Sample	145.460 baris
Jumlah Fitur	11 fitur numerik
Variabel Target	RainClass: No Rain, Light Rain, Heavy Rain
Distribusi Kelas	No Rain: 64,05%; Light Rain: 29,43%; Heavy Rain: 6,52%
Imbalance Ratio	~9,82:1 (No Rain vs Heavy Rain)

Tabel 3.4 Deskripsi Fitur Dataset Rain in Australia

Fitur	Deskripsi
MinTemp	Suhu minimum harian (°C)
MaxTemp	Suhu maksimum harian (°C)
WindGustSpeed	Kecepatan hembusan angin terkuat (km/h)
WindSpeed9am	Kecepatan angin pukul 09.00 (km/h)
WindSpeed3pm	Kecepatan angin pukul 15.00 (km/h)
Humidity9am	Kelembapan relatif pukul 09.00 (%)
Humidity3pm	Kelembapan relatif pukul 15.00 (%)
Pressure9am	Tekanan udara pukul 09.00 (hPa)
Pressure3pm	Tekanan udara pukul 15.00 (hPa)
Temp9am	Suhu pukul 09.00 (°C)
Temp3pm	Suhu pukul 15.00 (°C)

3.3 Prosedur Eksperimen

3.3.1 Pembagian Data (*Train-Test Split*)

Data dibagi menjadi training set (80%) dan test set (20%) menggunakan stratified sampling untuk menjaga proporsi kelas target. Pembagian dilakukan sebelum preprocessing apapun untuk menghindari data leakage.

Python

```
X_latih, X_uji, y_latih, y_uji = train_test_split(
    X, y,
    test_size=0.2,           # 20% untuk data uji
    random_state=42,         # agar hasil bisa diulang
    stratify=y               # pertahankan proporsi kelas
)

print(f'Data latih (training set) : {X_latih.shape[0]:,} sampel')
print(f'Data uji (test set)       : {X_uji.shape[0]:,} sampel')
print()
print('Distribusi kelas di data latih:')
for i, nama in enumerate(encoder.classes_):
    jumlah = (y_latih == i).sum()
    print(f' {nama}: {jumlah:,} ({jumlah / len(y_latih) * 100:.1f}%)')
```

3.3.2 Metode Resampling yang Digunakan

Dalam penelitian ini, digunakan 4 metode *Resampling* yang dibandingkan :

1. Baseline

Model yang dilatih menggunakan data asli tanpa teknik penanganan ketidakseimbangan kelas sebagai pembandingan awal. Dipilih untuk mengidentifikasi dampak negatif ketidakseimbangan data terhadap performa klasifikasi standar.

2. Random Undersampling (RUS)

Teknik yang mengurangi jumlah sampel kelas mayoritas secara acak hingga proporsinya seimbang dengan kelas minoritas. Dipilih karena metodenya sangat cepat dan praktis untuk diimplementasikan.

3. NearMiss-1

Teknik undersampling berbasis jarak yang hanya mempertahankan sampel mayoritas dengan jarak rata-rata terdekat terhadap tiga sampel kelas minoritas terdekat. Dipilih karena sifatnya yang jauh lebih selektif dalam memilih data dibandingkan metode RUS.

4. Hybrid Oversampling and Undersampling Method (HOUM)

Metode gabungan yang mengintegrasikan *SVM-based undersampling* untuk menghapus data mayoritas yang jauh dari batas keputusan dan *Safe-Level SMOTE* untuk membangkitkan data minoritas baru di area aman secara iteratif. Dipilih karena kemampuannya mencegah hilangnya data penting sekaligus menghindari *overfitting* yang sering terjadi pada proses *oversampling* biasa.

3.3.3 Algoritma Klasifikasi

Penelitian ini menggunakan Random Forest sebagai classifier pada seluruh skenario eksperimen. Random Forest merupakan algoritma kombinasi model yang membangun sejumlah decision tree secara paralel, di mana setiap tree dilatih menggunakan subsampel data yang berbeda melalui teknik sampling dengan pengembalian (resampling). Prediksi akhir kemudian ditentukan berdasarkan mekanisme voting mayoritas dari seluruh tree [10].

Pemilihan Random Forest dalam penelitian ini didasarkan pada beberapa pertimbangan. Pertama, algoritma ini relatif robust terhadap noise, karena proses averaging antar banyak tree mampu menekan risiko overfitting, yang relevan mengingat data sintesis dari SL-SMOTE berpotensi menambah noise [10]. Kedua, Random Forest tidak bergantung pada asumsi distribusi data tertentu, sehingga sesuai untuk karakteristik data oseanografi yang distribusinya tidak selalu diketahui. Ketiga, algoritma ini cukup stabil untuk digunakan sebagai baseline classifier, sehingga memungkinkan perbandingan antar metode resampling dilakukan secara lebih objektif tanpa dipengaruhi kompleksitas model [7].

Konfigurasi yang digunakan dibuat konsisten pada seluruh skenario, yaitu $n_estimators = 100$ (jumlah decision tree), $random_state = 42$ (seed untuk reproduksibilitas), dan $n_jobs = -1$ (pemrosesan paralel pada seluruh core yang tersedia). Tidak dilakukan hyperparameter tuning, karena parameter yang digunakan merupakan nilai standar yang cukup representatif, sehingga fokus evaluasi tetap berada pada efektivitas metode resampling, bukan pada optimasi model.

3.3.4 Metrik Evaluasi

Dengan mempertimbangkan tingkat ketidakseimbangan kelas yang sangat tinggi pada dataset ini, penggunaan *accuracy* saja dinilai kurang representatif karena dapat menimbulkan accuracy paradox [1]. Oleh sebab itu, penelitian ini memanfaatkan enam metrik evaluasi yang lebih komprehensif pada Tabel 3.5 berikut:

Tabel 3.5 Metrik Evaluasi yang Digunakan

Metrik	Keterangan	Alasan Dipilih
Accuracy	Proporsi prediksi yang benar secara keseluruhan	Sebagai pembanding awal
Precision (macro)	Rata-rata ketepatan prediksi per kelas	Mengukur seberapa banyak prediksi positif yang benar
Recall (macro)	Rata-rata kemampuan mendeteksi sampel asli per kelas	Penting untuk mendeteksi kelas minoritas

Metrik	Keterangan	Alasan Dipilih
F1-Score (macro)	Harmonic mean dari Precision dan Recall	Metrik utama untuk menyeimbangkan Precision dan Recall [1]
G-Mean	Akar rata-rata Sensitivity dan Specificity	Memberikan penalti besar jika salah satu kelas gagal terdeteksi [8]
AUC-ROC	Kemampuan diskriminasi model antar kelas	Tidak bergantung pada threshold tertentu


Semua metrik dihitung menggunakan pendekatan macro-average agar setiap kelas mendapat bobot yang sama, sehingga hasil evaluasi tidak terpengaruh oleh dominasi kelas Smooth.

BAB IV


HASIL DAN PEMBAHASAN

4.1 Eksplorasi Data (EDA)

Sebelum melakukan pemodelan, dilakukan eksplorasi data untuk memahami karakteristik dataset secara menyeluruh. EDA bertujuan untuk melihat distribusi kelas, sebaran nilai fitur, hubungan antar fitur, dan potensi masalah data seperti nilai kosong atau pencilan



Gambar 4.1 Distribusi kelas gelombang dan sebaran Hsig(m) per kategori




Gambar 4.2 Distribusi Fitur Oseanografi per Kelas Gelombang

4.1.1 Interptestasi EDA


Berdasarkan Gambar 4.1, dataset gelombang oseanografi memiliki ketidakseimbangan kelas yang signifikan. Kelas *Smooth* mendominasi dengan 84,98% dari total sampel, sedangkan kelas *Slight* dan *Moderate* masing - masing hanya sebesar 6,38% dan 8,65%. Nilai

Imbalance Ratio antara kelas *Smooth* dan *Slight* mencapai sekitar 13:1, yang termasuk kategori ketidakseimbangan tinggi dan berpotensi menyebabkan bias model.

Boxplot pada Gambar 4.2 menunjukkan bahwa tinggi gelombang signifikan (*Hsig*) memiliki rentang yang berbeda jelas antar kelas. Kelas *Smooth* memiliki nilai *Hsig* yang rendah dan terpusat, sementara *Moderate* memiliki distribusi yang lebih lebar dengan nilai lebih tinggi. Hal ini mengindikasikan bahwa fitur *Hsig(m)* bersifat sangat diskriminatif yang berarti fitur ini sangat membantu membedakan satu kelas dari kelas lain.



Gambar 4.3 Heatmap korelasi antar fitur dataset gelombang




Gambar 4.4 Distribusi kelas pada keempat skenario resampling (data latih)


4.1.2 Interpretasi Preprocessing dan Resampling

Gambar 4.4 menampilkan perbedaan distribusi kelas yang dihasilkan oleh masing-masing teknik resampling pada data latih. Pada skenario *Baseline*, ketidakseimbangan ekstrem tetap dipertahankan sehingga model yang dilatih diperkirakan sangat bias terhadap kelas *Smooth*. *RUS* dan *NearMiss-1* menghasilkan distribusi yang jauh lebih seimbang dengan mengurangi secara drastis jumlah sampel mayoritas. Namun, pengurangan yang drastis ini berarti banyak informasi dari kelas *Smooth* yang hilang. Data latih menjadi sangat kecil, yang bisa mempengaruhi kemampuan generalisasi model.

HOUM menghasilkan distribusi yang lebih moderat: jumlah mayoritas dikurangi secara selektif (hanya yang jauh dari batas keputusan), sementara kelas minoritas diperkaya melalui *Safe-Level SMOTE*. Hasilnya adalah data latih yang lebih seimbang namun tetap mempertahankan informasi penting



Gambar 4.5 Perbandingan Metrik Evaluasi per Skenario Resampling



Gambar 4.6 Confusion Metrik Keempat Skenario Resampling

4.2 Pembahasan

Berdasarkan Tabel 3.1 dan Gambar 4.5, terdapat perbedaan yang jelas antara keempat skenario resampling dalam kemampuannya mendeteksi kelas gelombang minoritas

Skenario **Baseline** menunjukkan Accuracy yang tampak tinggi, namun nilai Recall dan G-Mean pada kelas *Slight* dan *Moderate* sangat rendah. Ini adalah contoh nyata dari *accuracy paradox* — model hanya belajar memprediksi kelas *Smooth* yang dominan, sehingga terlihat akurat secara keseluruhan tetapi gagal mendeteksi kelas yang justru lebih penting

RUS dan **NearMiss-1** berhasil meningkatkan Recall kelas minoritas secara signifikan dibandingkan Baseline. Keduanya menyeimbangkan distribusi dengan mengurangi drastis jumlah sampel mayoritas. Namun, penurunan Precision menunjukkan bahwa model menjadi terlalu agresif — terlalu banyak prediksi positif yang salah. **RUS** kehilangan banyak informasi karena penghapusan dilakukan secara acak, sementara **NearMiss-1** meskipun lebih selektif, tetap berisiko membuang sampel mayoritas yang informatif

HOUM menunjukkan keunggulan dalam menjaga keseimbangan antara Precision dan Recall, yang tercermin pada nilai F1-Score dan G-Mean yang lebih kompetitif. SVM-based undersampling memastikan hanya sampel mayoritas yang jauh dari batas keputusan yang dihapus, sehingga model tetap punya informasi yang cukup untuk menghindari terlalu banyak *false positive*. Safe-Level SMOTE memperkaya kelas minoritas hanya di area yang aman, menghasilkan sampel sintesis berkualitas tinggi. Nilai AUC **HOUM** pada kelas *Slight* dan *Moderate* yang lebih tinggi secara konsisten dibandingkan dengan Baseline mengonfirmasi efektivitas pendekatan hybrid ini.

BAB V

KESIMPULAN

5.1 Kesimpulan

Berdasarkan eksperimen yang telah dilakukan pada dataset gelombang oseanografi dari enam lokasi di Indonesia, dapat disimpulkan:

1. Dataset gelombang memiliki ketidakseimbangan kelas tinggi dengan *Imbalance Ratio* ~13:1 antara kelas *Smooth* dan *Slight*. Kondisi ini terbukti menyebabkan model Baseline memiliki nilai *Recall* dan *G-Mean* yang sangat rendah pada kelas minoritas, mengkonfirmasi perlunya teknik penanganan khusus.
2. Dibandingkan dengan RUS dan *NearMiss-1*, HOUM menghasilkan keseimbangan lebih baik antara *Precision* dan *Recall*, tercermin pada nilai *F1-Score* dan *G-Mean* yang lebih kompetitif. HOUM meningkatkan kemampuan deteksi kelas gelombang minoritas tanpa menurunkan performa pada kelas mayoritas secara drastis.
3. HOUM terbukti lebih adaptif karena menggabungkan dua mekanisme yang saling melengkapi: SVM-based undersampling yang mempertahankan struktur decision boundary yang kritis, dan *Safe-Level* SMOTE yang menghasilkan sampel sintetis hanya di area yang aman. Kombinasi ini mengatasi dua kelemahan utama secara bersamaan hingga kehilangan informasi akibat *undersampling* acak dan *overfitting* akibat *oversampling* yang tidak terkontrol.

5.2 Keterbatasan

1. Dataset terbatas pada enam lokasi dan satu periode waktu, mana perlu di generalisasi ke kondisi perairan lain dan juga perlu validasi lebih lanjut.
2. Evaluasi menggunakan single train-test split; k-fold cross-validation akan memberikan estimasi yang lebih stabil.
3. Hanya satu classifier (Random Forest) yang digunakan dan hasilnya mungkin berbeda dengan SVM atau XGBoost.
4. Parameter HOUM menggunakan nilai default yang optimasi hyperparameter berpotensi meningkatkan performa.

5.3 Saran

1. Gunakan *k-fold cross-validation* (k=5) untuk evaluasi yang lebih *robust*.
2. Coba beberapa *classifier* (SVM, XGBoost, KNN) untuk melihat konsistensi efektivitas HOUM.
3. Lakukan hyperparameter tuning pada parameter *ratio_hapus* dan *ratio_target* HOUM.
4. Eksplorasi metode hybrid lain seperti SMOTEENN atau SMOTETomek sebagai pembanding tambahan.

DAFTAR PUSTAKA

- [1] H. He dan E. A. Garcia, "Learning from Imbalanced Data," *IEEE Transactions on Knowledge and Data Engineering*, vol. 21, no. 9, pp. 1263–1284, Sep. 2009, doi: 10.1109/TKDE.2008.239.
- [2] N. V. Chawla, K. W. Bowyer, L. O. Hall, dan W. P. Kegelmeyer, "SMOTE: Synthetic Minority Over-sampling Technique," *Journal of Artificial Intelligence Research*, vol. 16, pp. 321–357, 2002, doi: 10.1613/jair.953.
- [3] B. X. Wang dan N. Japkowicz, "Boosting support vector machines for imbalanced data sets," *Knowledge and Information Systems*, vol. 25, no. 1, pp. 1–20, 2010.
- [4] D. Yilmaz Eroglu dan M. S. Pir, "Hybrid Oversampling and Undersampling Method (HOUM) via Safe-Level SMOTE and Support Vector Machine," *Applied Sciences*, vol. 14, no. 22, 2024, doi: 10.3390/app142210438.
- [5] J. Zhang dan I. Mani, "KNN Approach to Unbalanced Data Distributions," dalam *Proc. ICML Workshop on Learning from Imbalanced Datasets*, Washington DC, 2003.
- [6] A. Zughrat, M. Mahfouf, Y. Y. Yang, dan S. Thornton, "Support Vector Machines for Class Imbalance Rail Data Classification," *IFAC Proceedings Volumes*, vol. 47, no. 3, pp. 8756–8761, 2014.
- [7] M. Mujahid et al., "Data oversampling and imbalanced datasets: an investigation of performance for machine learning and feature engineering," *Journal of Big Data*, vol. 11, no. 1, 2024, doi: 10.1186/s40537-024-00943-4.
- [8] Trisanto et al., "Effectiveness Undersampling Method and Feature Reduction in Credit Card Fraud Detection," *International Journal of Intelligent Engineering and Systems*, vol. 13, no. 2, pp. 173–181, Apr. 2020, doi: 10.22266/ijies2020.0430.17.
- [9] C. Bunkhumpornpat, K. Sinapiromsaran, dan C. Lursinsap, "Safe-Level-SMOTE," dalam *Lecture Notes in Computer Science*, Springer, 2009, pp. 475–482, doi: 10.1007/978-3-642-01307-2_43.
- [10] L. Breiman, "Random Forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001, doi: 10.1023/A:1010933404324.

LAMPIRAN

[Repositori GitHub](#)